GUIDE DE RÉALISATION DU PROJET

# Prédiction de l’abandon et de la réussite académique

Projet complet de Data Science et de développement

| Technologie | Rôle dans le projet |
|---|---|
| Python | Analyse des données et Machine Learning |
| SQL Server | Stockage des données et des prédictions |
| Flask + HTML/CSS | Application web de prédiction |
| Power BI | Tableaux de bord et indicateurs |
| Git / GitHub | Versionnement et partage du projet |

**Objectif :** construire une solution capable d’estimer si un étudiant est susceptible d’abandonner ses études, de rester inscrit ou d’obtenir son diplôme, afin d’aider les équipes pédagogiques à mieux accompagner les étudiants.

Guide pratique — version de démarrage

# 1. Présentation du projet

**Problématique :** comment exploiter les données scolaires et socioéconomiques pour estimer le devenir académique des étudiants et aider les établissements à intervenir plus tôt ?

**Objectif général :** développer une solution intégrée combinant analyse des données, Machine Learning, base de données, application web et visualisation.

## Objectifs spécifiques

• Analyser et préparer les données du dataset.

• Identifier les facteurs associés aux trois résultats académiques.

• Entraîner et évaluer plusieurs modèles de classification.

• Enregistrer les données nécessaires et les prédictions dans SQL Server.

• Développer une application web permettant de saisir les caractéristiques d'un étudiant.

• Créer des tableaux de bord Power BI pour explorer les données et les résultats.

• Documenter le projet et vérifier la fiabilité des prédictions.

# 2. Comprendre le dataset

Selon la description fournie, le dataset contient 4 424 étudiants, 36 variables et trois catégories cibles. Il ne comporte pas de valeurs manquantes après le prétraitement initial indiqué par la source ; cette information doit néanmoins être vérifiée sur le fichier téléchargé.

| Classe | Signification |
|---|---|
| Dropout | L'étudiant a abandonné ses études. |
| Enrolled | L'étudiant est toujours inscrit ; cela ne signifie pas qu'il a échoué. |
| Graduate | L'étudiant a obtenu son diplôme. |

Les variables couvrent notamment le parcours scolaire antérieur, la formation, certaines caractéristiques démographiques et socioéconomiques, ainsi que les résultats du premier et du deuxième semestre.

# 3. Choix techniques

| Outil | Utilisation |
|---|---|
| Python, Pandas, NumPy | Préparation, analyse et transformation des données. |
| Matplotlib, Seaborn | Graphiques exploratoires. |
| Scikit-learn | Pipelines, entraînement et évaluation des modèles. |
| Joblib | Sauvegarde du pipeline de modèle. |
| Flask, HTML, CSS | Formulaire web et affichage des prédictions. |
| SQL Server + SSMS | Stockage relationnel et interrogation des données. |
| Power BI Desktop | Rapport interactif et indicateurs. |
| Git / GitHub | Historique du code et documentation. |

# 4. Architecture et organisation des fichiers

Le travail principal sera réalisé localement pour limiter la dépendance à Internet. Google Colab pourra servir aux expérimentations lorsque la connexion sera disponible. Les fichiers importants devront être sauvegardés sur l'ordinateur.

```
student_dropout_prediction/
├── data/
│   ├── bronze/       # données originales, non modifiées
│   ├── silver/       # données nettoyées
│   └── gold/         # données prêtes pour l'analyse/modélisation
├── notebooks/
│   ├── 01_data_audit.ipynb
│   ├── 02_exploratory_analysis.ipynb
│   ├── 03_data_preparation.ipynb
│   ├── 04_model_training.ipynb
│   └── 05_model_evaluation.ipynb
├── src/
│   ├── preprocessing.py
│   ├── train_model.py
│   └── predict.py
├── models/
├── app/
│   ├── main.py
│   ├── templates/
│   └── static/
├── sql/
├── powerbi/
├── tests/
├── requirements.txt
├── .gitignore
└── README.md
```

# 5. Phases de réalisation

| Phase | Travail | Livrable |
|---|---|---|
| 1 | Audit et compréhension des données | Notebook d'audit |
| 2 | Analyse exploratoire | Graphiques et constats |
| 3 | Nettoyage et préparation | Données préparées |
| 4 | Entraînement et évaluation | Pipeline de modèle validé |
| 5 | Conception SQL Server | Base et tables |
| 6 | Application Flask | Formulaire et page de résultat |
| 7 | Power BI | Tableau de bord |
| 8 | Tests et documentation | Projet documenté et vérifié |

# 6. Application web envisagée

**Accueil :** présentation du projet et accès au formulaire.

**Formulaire :** saisie des variables nécessaires à la prédiction. Les champs définitifs seront déterminés après l'audit des données et le choix du scénario de prédiction.

**Résultat :** classe prédite et probabilités estimées pour Dropout, Enrolled et Graduate, si le modèle permet de les calculer.

**Historique :** consultation des prédictions enregistrées dans SQL Server, en limitant les données personnelles.

## 7. Tableau de bord Power BI

**Page 1 — Vue générale :** nombre d'étudiants, répartition par catégorie, taux d'abandon observé et comparaison par formation.

**Page 2 — Analyse :** comparaison des catégories selon les caractéristiques et résultats disponibles. Une association statistique ne prouve pas une causalité.

**Page 3 — Modèle :** accuracy, precision, recall, F1-score, matrice de confusion et volume des prédictions.

## 8. Point essentiel : choisir le moment de la prédiction

Pour une prédiction dès l'inscription, les résultats des semestres futurs doivent être exclus des variables d'entrée. Nous commencerons donc par un modèle utilisant uniquement les informations disponibles à l'inscription. Un second modèle pourra ensuite intégrer les résultats du premier semestre afin de comparer les performances à un stade plus avancé du parcours.

Le dataset présente un déséquilibre entre les classes. L'accuracy ne suffira donc pas : il faudra examiner notamment le rappel de la classe Dropout et la matrice de confusion. Les prédictions sont des estimations et ne doivent pas, seules, entraîner une décision défavorable envers un étudiant.

# 9. Préparer l’environnement local

Dans Visual Studio Code, ouvrez le dossier du projet puis choisissez Terminal → Nouveau terminal. Les commandes ci-dessous sont destinées à PowerShell sous Windows.

## Vérifier Python

```
python --version
# Si nécessaire :
py --version
```

## Créer un environnement virtuel

```
python -m venv .venv
# Si la commande python n’est pas reconnue :
py -m venv .venv
```

## Activer l’environnement

```
.\.venv\Scripts\Activate.ps1
```

## Installer les bibliothèques (connexion Internet nécessaire)

```
python -m pip install pandas numpy matplotlib seaborn scikit-learn jupyter ipykernel joblib flask pyodbc
```

Si PowerShell bloque l’activation, ne changez pas immédiatement les paramètres de sécurité : signalez le message d’erreur afin d’utiliser une autre méthode.

# 10. Plan de travail même avec une connexion instable

• Conserver le CSV original dans data/bronze et ne jamais l’écraser.

• Enregistrer régulièrement les notebooks, scripts et résultats sur le disque local.

• Utiliser Colab lorsque la connexion est disponible, puis télécharger les fichiers importants.

• Travailler localement avec VS Code, Jupyter, SQL Server et Power BI Desktop lorsque les outils sont installés.

• Versionner le code avec Git et publier sur GitHub lorsque la connexion le permet.

# 11. Première tâche à réaliser

1. Créer le dossier student_dropout_prediction sur l’ordinateur.
2. L’ouvrir dans Visual Studio Code.
3. Créer les dossiers data/bronze, data/silver, data/gold, notebooks, src, models, app, sql, powerbi et tests.
4. Copier le CSV téléchargé dans data/bronze sans modifier son contenu.
5. Ouvrir un terminal et exécuter python --version.
6. Noter le nom exact du CSV et le résultat de la commande Python.

**Suite du travail :** création du notebook 01_data_audit.ipynb, vérification des 36 variables, des types, des doublons, des valeurs manquantes et de la répartition de la cible.